

Задание 3. Архитектура сети.

	config	param	output feat
conv ₁	7x7, S2, 3→32	$7 \times 7 \times 3 \times 3^2 = 4704$	$32 \cdot \frac{5}{2} \cdot \frac{5}{2}$
max pool	3x3, S2, 1p1	-	$32 \cdot \frac{5}{4} \cdot \frac{5}{4}$
conv ₂	5x5, 32→64	$5 \times 5 \cdot 32 \cdot 64 = 51200$	$64 \cdot \frac{5}{4} \cdot \frac{5}{4}$
conv ₃	3x3, S2, 64→128	$3 \cdot 3 \cdot 64 \cdot 128 = 73728$	$128 \cdot \frac{5}{8} \cdot \frac{5}{8}$
conv ₄	1x1, 128→256	$1 \cdot 1 \cdot 128 \cdot 256 = 32768$	$256 \cdot \frac{5}{16} \cdot \frac{5}{16}$
conv ₅	3x3, S2, 256→256	$3 \cdot 3 \cdot 256 \cdot 256 = 589824$	$256 \cdot \frac{5}{16} \cdot \frac{5}{16}$
conv ₆	1x1, 256→512	$1 \cdot 1 \cdot 256 \cdot 512 = 131072$	$512 \cdot \frac{5}{16} \cdot \frac{5}{16}$
GAP	-	-	512
FC ₁	512→256	$512 \cdot 256 + 256 = 131328$	256
FC ₂	256→100	$256 \cdot 100 + 100 = 25700$	100

Convolution param: $4704 + 51200 + 73728 + 32768 + 589824 + 131072 = 883296$ (without bias)

BN param: $4 \times \text{channel} (32 + 64 + 128 + 256 + 256 + 512) = 4992$

linear param: $131328 + 25700 = 157028$ (with bias)

Total param: $883296 + 4992 + 157028 = 1045316$

MB: $4 \cdot 1045316 / 1024 / 1024 = 3.98 \text{ MB}$

Flops.

PH BT CP CT PT CB BC

Flops for conv: $2 \cdot B \cdot C_{out} \cdot C_{in} \cdot H_{out} \cdot W_{out} \cdot k^2$

Flops for BN: $2 \cdot C_{out} \cdot H_{out} \cdot W_{out}$

Flops for Relu: $C_{out} \cdot H_{out} \cdot W_{out}$

layer	Conv	BN	Relu	Pool
conv ₁ + max pool	$2 \cdot 32 \cdot 3 \cdot 2^2 \cdot \frac{1}{2^2} = 2352$	$2 \cdot 32 \cdot \frac{1}{2^2} = 16$	$32 \cdot \frac{1}{2^2} = 8$	$8 \cdot 32 \cdot \frac{1}{4^2} = 16$
conv ₂	$2 \cdot 32 \cdot 64 \cdot 5^2 \cdot \frac{1}{4^2} = 6400$	$2 \cdot 64 \cdot \frac{1}{4^2} = 8$	$64 \cdot \frac{1}{4^2} = 4$	
conv ₃	2304	4	2	
conv ₄	1024	8	4	
conv ₅	4608	2	1	
conv ₆ + GAP	1024	4	2	2

$$FC_1: 2 \cdot 512 \cdot 256 + 256 = 262400$$

By line constn: Relu: 256

$$FC_2: 2 \cdot 256 \cdot 100 + 100 = 51300$$

$$\text{Urozo: Flops} = 17793 \cdot B \cdot S^2 + 314468 \cdot B$$

Urozo Flops

2392

6412

2310

1036

4611

1032

(+512 - general no konomy)

17793

Peak memory

в микровей памяти хранятся только промежуточные и входные узлы + model parameters (это константа) + итерационная картинка

	input ($\times \text{BS}^2$)	log scale (BS^2)	block scale (BS^2)	Don.
conv ₁	3	8	8	
bn ₁	3	8	8	
relu ₁	3	8	-	
max pool	3	8	2	4 (input-index)
conv ₂ /bn ₂	3	2/4	4/4	
conv ₃ /bn ₃	3	4/2	2/2	
conv ₄ /bn ₄	3	2/4	4/4	
conv ₅ /bn ₅	3	4/1	1/1	
conv ₆ /bn ₆	3	1/2	2/2	

нуж памяти: 4 parameters + $4 \cdot 19 \text{ BS}^2 = 3.98 \text{ MB} + 76 \text{ BS}^2$

параметры

11 - нуль

17

9/11

9/7

9/11

8/5

6/7

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

5

Bytes Moved.

$$Q_{op} = 4(\text{number of layers} + \text{number of nodes}) + \text{bytes moved}$$

Layer	Number of nodes, bytes/s^2	Bytes	Flops/ s^2	Unreduced, Flop/Byte
conv ₁	$4(3+8) = 44$	18816	2352	53
bn ₁	64	...	16	0.25
relu ₁	64	...	8	0.125
max pool	$4(8+2) + 8 \cdot 2 = 56$	...	16	0.29
conv ₂	$4(2+4) = 24$	204800	6400	267
bn ₂	32	...	8	0.25
relu ₂	32	...	4	0.125
conv ₃	$4(4+2) = 24$	294912	2304	96
bn ₃	16	...	4	0.25
relu ₃	16	...	2	0.125
conv ₄	$4(2+4) = 24$	131072	1024	43
bn ₄	32	...	8	0.25
relu ₄	32	...	4	0.125
conv ₅	$4(4+1) = 20$	2359296	4608	230
bn ₅	8	...	2	0.25
relu ₅	8	...	1	0.125
conv ₆	$4(1+2) = 12$	524288	1024	85
bn ₆	16	...	4	0.25
relu ₆	16	...	2	0.125
GAP	8	...	2	0.25
	$= 548$	$= P$	17793	Avg 32.5

$$Q = 548 BS^2 + P$$

memory vs
fast square

latency rtx 3090

PH BT CP CT PT CS BC

$t_0 = 19.7$ мкс/опер - время задержки

$\beta_0 = 1140$ ГБ/с - пропускная способность памяти

$\pi_0 = 13.0$ ТФЛОП/с - производительность FP32

← из пред. задачи

$$\text{latency} = Z_e \max \left\{ t_0, \frac{\text{bytes}_e}{\beta_0}, \frac{\text{FLOPs}_e}{\pi_0} \right\}$$

$\uparrow$ задержка $\uparrow$ передать пакетов $\uparrow$ выполнить пакетов

потому что график latency vs batch size
выглядит 3 зонами: launch-mode (мало, когда
наимено пакетов $< t_0$)

- memory mode (преобладает $\frac{\text{bytes}_e}{\beta_0}$)
- compute mode (преобладает $\frac{\text{FLOPs}_e}{\pi_0}$)

energy

PH BT CP CT PT CS BC

$P_0 = 197$ Вт - потребление во время launch mode

$e_f = 13.7$ мДж/FLOP - потребление энергии на одну FP32 операцию (с памятью)

$P_0 + e_f \cdot \pi = 375$ Вт - полная мощность

$$E = P_0 \cdot \text{latency} + e_f \cdot \text{FLOPs}_e$$

- первое
напряжение
на forward