

ДЗ 1. Архитектура сети.

	config	param	output feat
conv ₁	7x7, S2, 3→32	$7 \times 7 \times 3 \times 32 = 4704$	$32 \cdot \frac{5}{2} \cdot \frac{5}{2}$
max pool	3x3, S2, P1	-	$32 \cdot \frac{5}{4} \cdot \frac{5}{4}$
conv ₂	5x5, 32→64	$5 \times 5 \cdot 32 \cdot 64 = 51200$	$64 \cdot \frac{5}{4} \cdot \frac{5}{4}$
conv ₃	3x3, S2, 64→128	$3 \cdot 3 \cdot 64 \cdot 128 = 73728$	$128 \cdot \frac{5}{8} \cdot \frac{5}{8}$
conv ₄	1x1, 128→256	$1 \cdot 1 \cdot 128 \cdot 256 = 32768$	$256 \cdot \frac{5}{16} \cdot \frac{5}{16}$
conv ₅	3x3, S2, 256→256	$3 \cdot 3 \cdot 256 \cdot 256 = 589824$	$256 \cdot \frac{5}{16} \cdot \frac{5}{16}$
conv ₆	1x1, 256→512	$1 \cdot 1 \cdot 256 \cdot 512 = 131072$	$512 \cdot \frac{5}{16} \cdot \frac{5}{16}$
GAP	-	-	512
FC ₁	512→256	$512 \cdot 256 + 256 = 131328$	256
FC ₂	256→100	$256 \cdot 100 + 100 = 25700$	100

Convolution param: $4704 + 51200 + 73728 + 32768 + 589824 + 131072 = 883296$ (without bias)

BN param: $4 \times \text{channel} (32 + 64 + 128 + 256 + 256 + 512) = 4992$

linear param: $131328 + 25700 = 157028$ (with bias)

Total param: $883296 + 4992 + 157028 = 1045316$
 MB: $4 \cdot 1045316 / 1024 / 1024 = \text{4.18 MB}$

Not counting num. batch. tracked.

Flops.

Flops for conv: $2 \cdot B \cdot C_{out} \cdot C_{in} \cdot H_{out} \cdot W_{out} \cdot k^2$

Flops for bn: $2 \cdot C_{out} \cdot H_{out} \cdot W_{out}$

Flops for relu: $C_{out} \cdot H_{out} \cdot W_{out}$

layer	conv	BN	Relu	Pool
conv ₁ + max pool	$2 \cdot 32 \cdot 3 \cdot 7^2 \cdot \frac{1}{2^2} = 2352$	$2 \cdot 32 \cdot \frac{1}{2^2} = 16$	$32 \cdot \frac{1}{2^2} = 8$	$8 \cdot 32 \cdot \frac{1}{4^2} = 16$
conv ₂	$2 \cdot 32 \cdot 64 \cdot 5^2 \cdot \frac{1}{4^2} = 6400$	$2 \cdot 64 \cdot \frac{1}{4^2} = 8$	$64 \cdot \frac{1}{4^2} = 4$	
conv ₃	2304	4	2	
conv ₄	1024	8	4	
conv ₅	4608	2	1	
conv ₆ + 6AP	1024	4	2	2

FC₁: $2 \cdot 512 \cdot 256 = 262144$
 Relu: 256
 FC₂: $2 \cdot 256 \cdot 100 = 51200$

U_{total}: Flops = $17793 B \cdot S^2 + 314112 B$
 $(262144 + 256 + 51200) B =$
 $= 17793 B S^2 + 314112 B$

U_{total} flops

2392
6412
2310
1036
4611
1032 (+512 - genuine no konomy)
17793

Peak memory

6 микробай на листе хранится только
предыдущий и следующий слой + model
parameters (это генератор) + изображения картинки

	input ($\times B^2$)	convolve (B^2)	convolve (B^2)	Pool
conv ₁	3	-	8	
bn ₁	3	8	8	
relu ₁	3	8	-	
max pool	3	8	2	4 (input - index)
conv ₂ / bn ₂	3	2/4	4/4	
conv ₃ / bn ₃	3	4/2	2/2	
conv ₄ / bn ₄	3	2/4	4/4	
conv ₅ / bn ₅	3	4/1	1/1	
conv ₆ / bn ₆	3	1/2	2/2	

нуж памяти: 4 parameters + 4.19 B^2 = ~~4.19~~ + 76 B^2
4.18 MB

параметры

11 - нуль
15 - нуль

11 - нуль

17 - нуль

9/11 - нуль

9/7 - нуль

9/11 - нуль

8/5 - нуль

6/7 - нуль

5/4 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

5/0 - нуль

bytes moved

$$Q_{op} = 4(\text{размеров } b_{avg} + n, b_{max}) + P.$$

слой	активации, байт/bs ²
conv ₁	$4(3 \cdot 8) = 44$
b ₁	$4(8 \cdot 8) = 64$
relu ₁	$4(8 \cdot 8) = 64$
maxpool ₁	$4(8 \cdot 2) = 40$
conv ₂	$4(2 \cdot 4) = 24$
b ₂	32
relu ₂	32
conv ₃	$4(4 \cdot 2) = 24$
b ₃	16
relu ₃	16
conv ₄	$4(2 \cdot 4) = 24$
b ₄	32
relu ₄	32
conv ₅	$4(4 \cdot 1) = 20$
b ₅	8
relu ₅	8
conv ₆	$4(1 \cdot 2) = 12$
b ₆	16
relu ₆	16
GAP	8

$$= 532 \text{ BS}^2$$

$$\text{консб.} = 4(512(\text{GAP}) + \underbrace{512+256}_{fc_1} + \underbrace{256+256}_{relu} + \underbrace{256+100}_{fc_2}) = 8592 \text{ B.}$$

bytes moved.

$$\text{итого: } \sqrt{532 \text{ BS}^2} + 8592 \text{ B} + 4.18 \text{ MB.}$$

memory mode
latency

rtx 3090

$t_0 = 19.7 \text{ нс}$ - время задержки + загрузка

$P_0 = 1140 \text{ ГБ/с}$ - пропускная способность памяти

$\pi_0 = 13.0 \text{ TFLOP/с}$ - производительность FP32

$$\text{latency} = \sum_e \max \left\{ t_0, \frac{\text{bytes}_e}{P_0}, \frac{\text{FLOPs}_e}{\pi_0} \right\}$$

$\uparrow$ загрузка $\uparrow$ размер пакета $\uparrow$ производительность пакета

потому что график latency vs batch size
делится на 3 зоны: launch-mode (мало, когда
размер пакета $< t_0$)

- memory mode (преобладает $\frac{\text{bytes}_e}{P_0}$)
- compute mode (преобладает $\frac{\text{FLOPs}_e}{\pi_0}$)

energy

$P_0 = 197 \text{ Вт}$ - потребление в режиме launch mode

$e_f = 13.7 \text{ мДж/FLOP}$ - потребление на один FLOP (с пакетом)

$P_0 + e_f \cdot \pi = 375 \text{ Вт}$ - мощность

$$E = P_0 \cdot \text{latency} + e_f \cdot \text{FLOPs}$$

- время на forward